1. **用 Weka 軟體對 contact-lenses.arff 建立 J48 決策樹，選擇 “Use training set” ，設定 Attribute: contact-lenses 為 Output，在過程中對重要步驟截圖並加以說明，並回答以下問題：**

步驟

i. 點選「Open file」，選擇檔案「contact-lenses.arff」

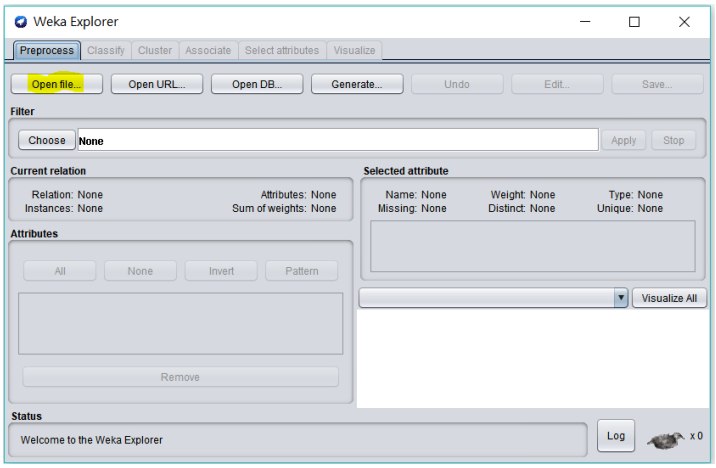

ii. 在 Classifier 點選「Choose」，選擇 weka/classifiers/trees/J48；在 Test options 選擇「Use training set」，；在 Start 上方的欄位選擇「(Nom)contact-lenses」。

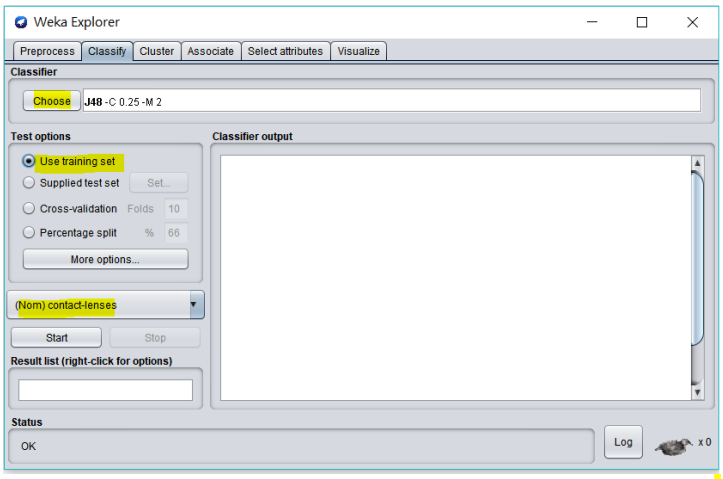

(a) 在前處理部分，右下角選擇不同屬性作為 Class，請解釋長條圖的數量、上方的數字以及不同顏色意義為何?(15%)

Attribute 屬性選擇了 spectacle-prescrip（包含了 myope, hypermetrope）

Class 選擇了 age（屬性值包含 young, pre-presbyopic, presbyopic）得到的直條圖則代表 myope 中 young, pre-presbyopic, presbyopic 各出現了多少次、hypermetrope 中 young, pre-presbyopic, presbyopic 各出現了多少次。

因此，長條圖的數量由 Attribute 決定、上方的數字代表 Attribute 中的各個屬性總共出現的次數、顏色種類由 Class 中的屬性值總數決定，每一種顏色代表 Class 中的一種屬性值。

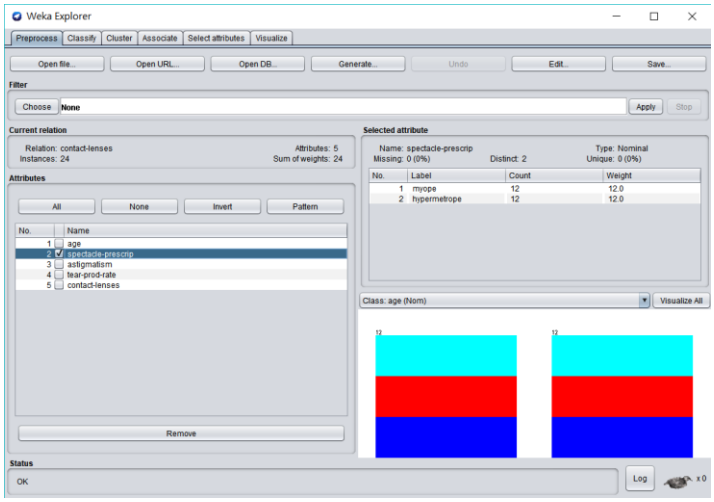

(b) 使用 Visualize Tree 或 Classifier Output 列出三個 Classification Rule 並解釋。(20%)

在 Result list 選取 Result，右鍵點選「Visualize tree」，即可看到決策樹。

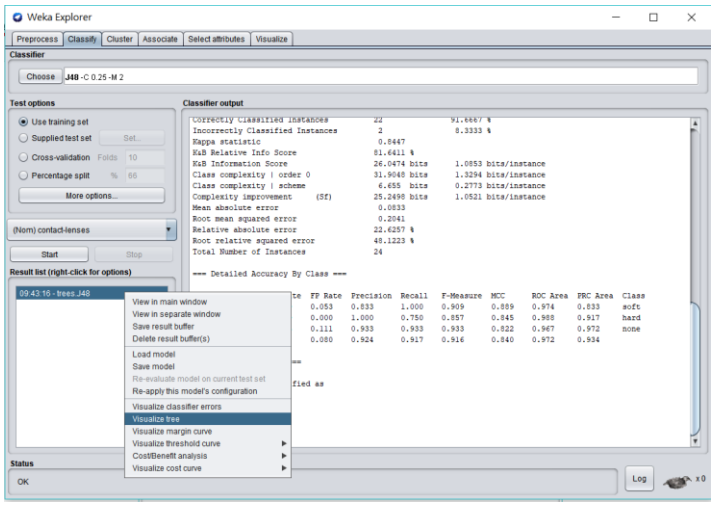

Tree 中的每一個節點 node（橢圓形），代表著不同的屬性測試，而最下方的葉 leaf（矩形），則代表分類的結果。由圖可以知道第一個 Classification Rule 是由 tear-prod-rate 屬於 reduced 還是 normal 分類，第二個 Classification Rule 是由 astigmatism 屬於 no 還是 yes 分類，第三個 Classification Rule 是由 spectacle-prescrip 屬於 myope 還是 hypermetrope 分類。

```
J48 pruned tree
------------------

tear-prod-rate = reduced: none (12.0)
tear-prod-rate = normal
|   astigmatism = no: soft (6.0/1.0)
|   astigmatism = yes
|   |   spectacle-prescrip = myope: hard (3.0)
|   |   spectacle-prescrip = hypermetrope: none (3.0/1.0)
```

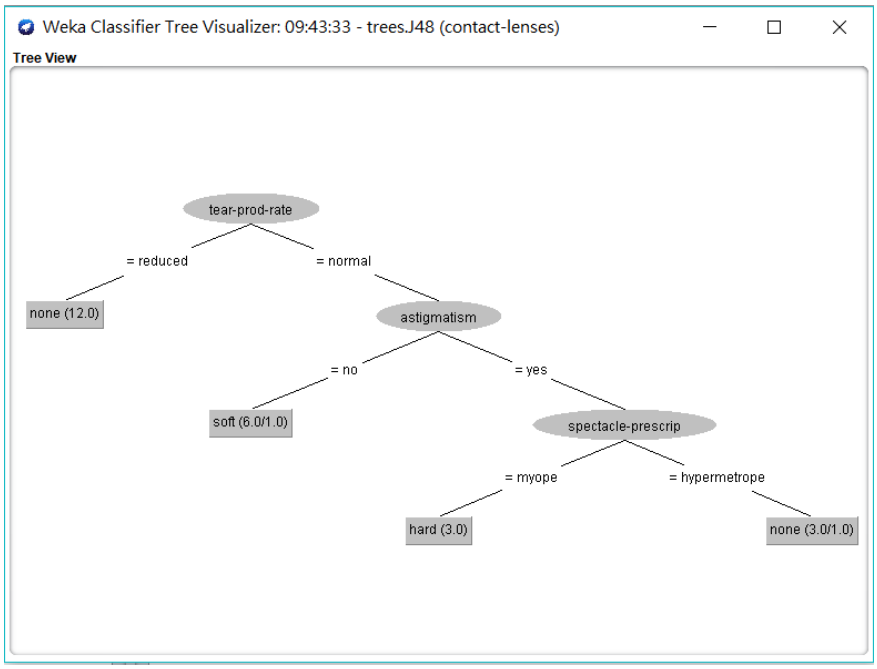

2. **請利用 weka 和 python 對 glass.csv 進行 Supervised learning 中的 DecisionTree 分析 ,並回答以下問題:**

   (a) **請運用 python 的 train_test_split 對 glass.csv 資料集，預測目標屬性為 Type 進行訓練集(66%)、測試集(34%)切分，請將重要程式碼截圖並說明(10%)**

   Python 部分：

   i. 新增指令使用套件「graphviz」

```
!pip install --upgrade pip --user
!pip install graphviz
import pandas as pd
import graphviz
from sklearn import preprocessing
from sklearn import tree
from sklearn import metrics
```

   ii. 讀取 glass.csv 檔案、設定 x:input 與 y:output、將 type 轉為數字 label、將 x 屬性合併成 list

```
#擷取CSV檔案
data = pd.read_csv('glass.csv')
```

切分input 和output

```
#x:input
x=data.loc[:,['RI','Na','Mg','Al','Si','K','Ca','Ba','Fe']]
#y:output
y=data.loc[:,['Type']]
```

轉換屬性及標籤型別

```
#轉換屬性型態
#將屬性轉為數字label
le = preprocessing.LabelEncoder()

#將type 轉為數字label
#type: build wind float: 0 ,build wind non-float: 1 ,vehic wind float: 2
#      containers: 3 ,headlamps: 4 ,tablewares: 5
Y_type_label=le.fit_transform(y['Type'])

#將屬性合併
#變成list
feature=list(zip(x.RI,x.Na,x.Mg,x.Al,x.Si,x.K,x.Ca,x.Ba,x.Fe))

#轉成array
import numpy as np
features=np.asarray(feature)
```

iii. 設定測試集為 0.34(34%)

切分訓練集與資料集

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(features, Y_type_label, test_size=0.34)
```

Weka 部分：

i. 點選「Open file」，選擇檔案「glass.arff」並在 Classifier 點選「Choose」，選擇 weka/classifiers/trees/J48。

ii. 選取「Percentage split」，輸入「66」。

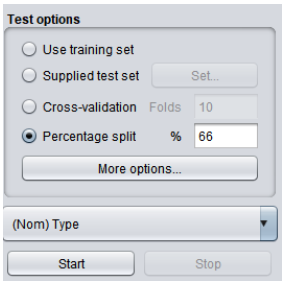

(b) 請利用參數(criterion = 'entropy', max_depth=3, max_leaf_nodes = 4)對切分出的訓練集進行訓練，並用 metrics.accuracy_score( )分別計算出模型對於訓練集和測試集的精準度，並與 WEKA 設定演算法 J48 Percentage spilt 66%

跑出的結果截圖說明並一起呈現比較(20%)

Python 部分：

設定 max_depth=3, max_leaf_nodes=4。

下圖為使用 python 輸出的測試集精準度及訓練集精準度。

切分訓練集與資料集

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(features, Y_type_label, test_size=0.34)
```

sklearn: DecisionTreeClassifier

```
clf = tree.DecisionTreeClassifier(criterion = 'entropy',max_depth=3,max_leaf_nodes = 4)
glass_clf = clf.fit(X_train,y_train)
```

測試模型

```
test_predicted = glass_clf.predict(X_test)
train_predicted = glass_clf.predict(X_train)

# 驗證準確度
test_accuracy = metrics.accuracy_score(test_predicted, y_test)
train_accuracy = metrics.accuracy_score(train_predicted, y_train)
print("測試集精準度: ",test_accuracy)
print("訓練集精準度: ",train_accuracy)
```

```
測試集精準度:  0.589041095890411
訓練集精準度:  0.6950354609929078
```

Weka 部分：

下圖為 Weka 輸出的精準度。

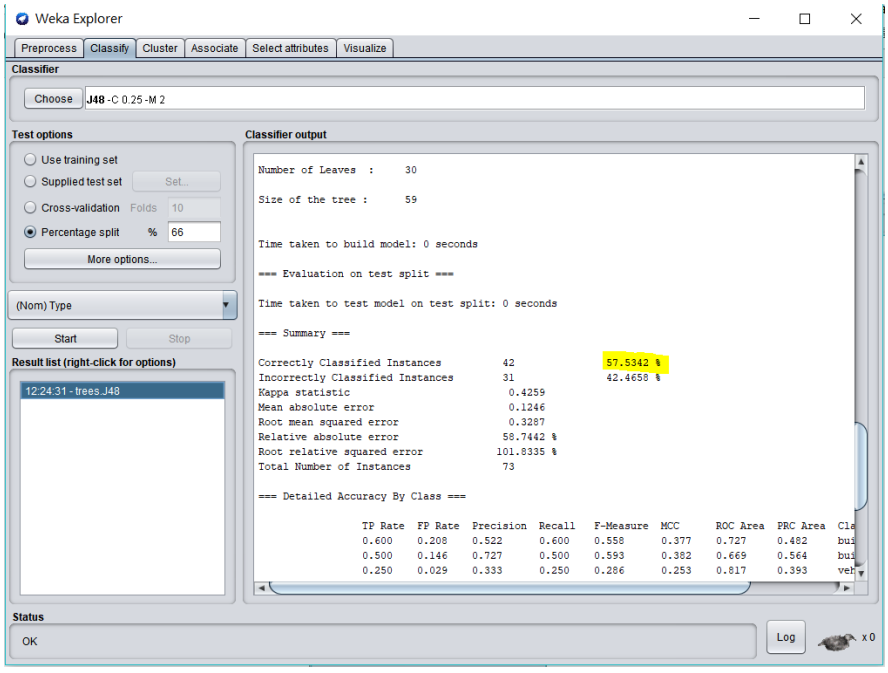

比較兩圖可以發現 Python 與 Weka 輸出的精準度有差異，原因

在於 Python 所切出的測試集與訓練集與 Weka 並不相同，所以結果也會不一樣。

(c) 請利用 graphviz 套件跑出決策樹圖形截圖並加以說明當中 X[?] 、samples、及 value 各代表的訊息，另外運用 WEKA visualize tree 觀察決策樹圖形並說明 WEKA 中葉節點的標籤及括號內的數字代表的意義。(20%)

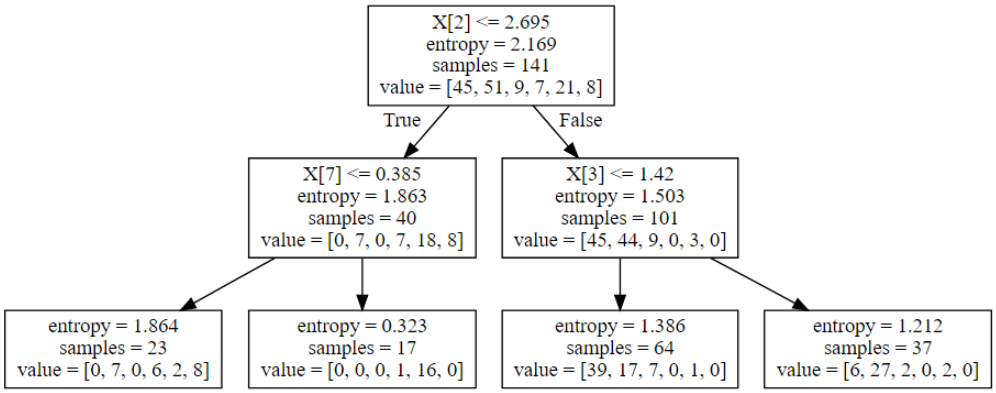

X[?] 表示使用哪些條件作為分類的區別。由 0-8 依序為 RI, Na, Mg, Al, Si, K, Ca, Ba, Fe。例如：第一層 X[2]<=2.169 表示 Mg 的量小於等於 2.169，若符合則歸類到 True，不符合則歸類到 FALSE，以此類推。

Sample 表示樣本數，因為我們將測試集設為 66% 因此這邊的樣本數量為 214*0.66 = 141。

Value 則是代表我們設定的 Attribute 各自有多少個樣本，從左

到右依序為 build wind float、build wind non-float、vehic wind float、containers、headlamps、tableware。

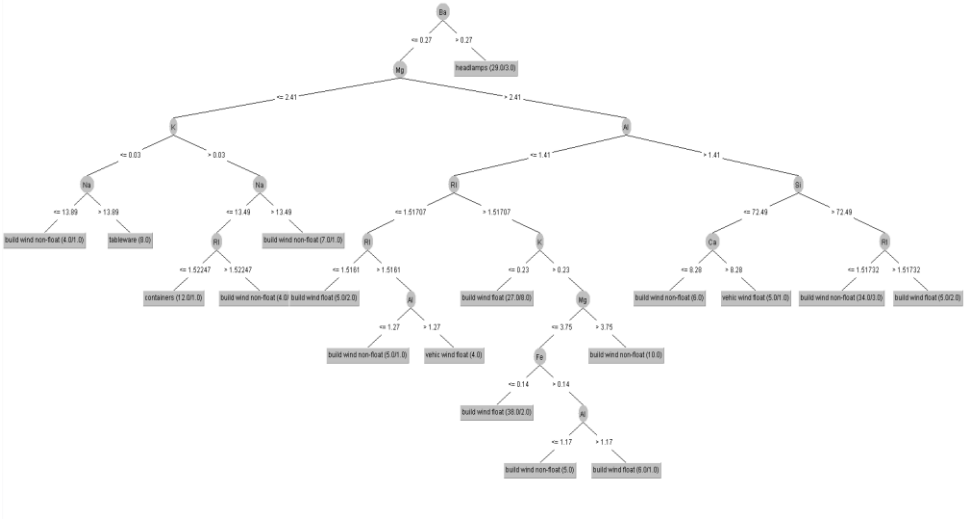

Weka 跑出來的決策樹可以很直覺的知道分類的規則及依據，如：節點的標籤（橢圓形）表示已什麼做為資料的劃分的依據，而線上的判斷式則提供了分類條件。而方框的文字則代表 Output Attribute，方框內的括弧內的數字左邊表示符合的數量，右邊則表示不符合的數量。

例如：Na 當作分類的依據，若 Na 小於或等於 13.89，則歸類到 build wind non-float，而有 4 筆是歸類正確，1 筆是歸類錯誤；若 Na 大於 13.89，則歸類到 tableware，而全部 8 筆都是歸類正確。

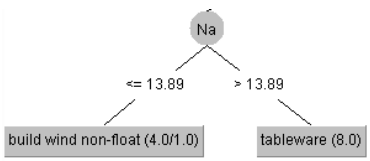

(d) 請試著調整 DecisionTreeClassifier 的參數，提升模型準確率，

請截圖並附上每次測試的結果(3~5 次)，觀察並說明準確率上升的原因，另外說明模型在訓練集的準確度通常較測試集的準確度高的原因為(15%)

首先比較參數值 minNumObj 的差異，測試集皆定為 66%

點選「Choose」右方的欄位進行參數設定。

將 minNumObj 修改成 4，得精準度為 64.3836%。

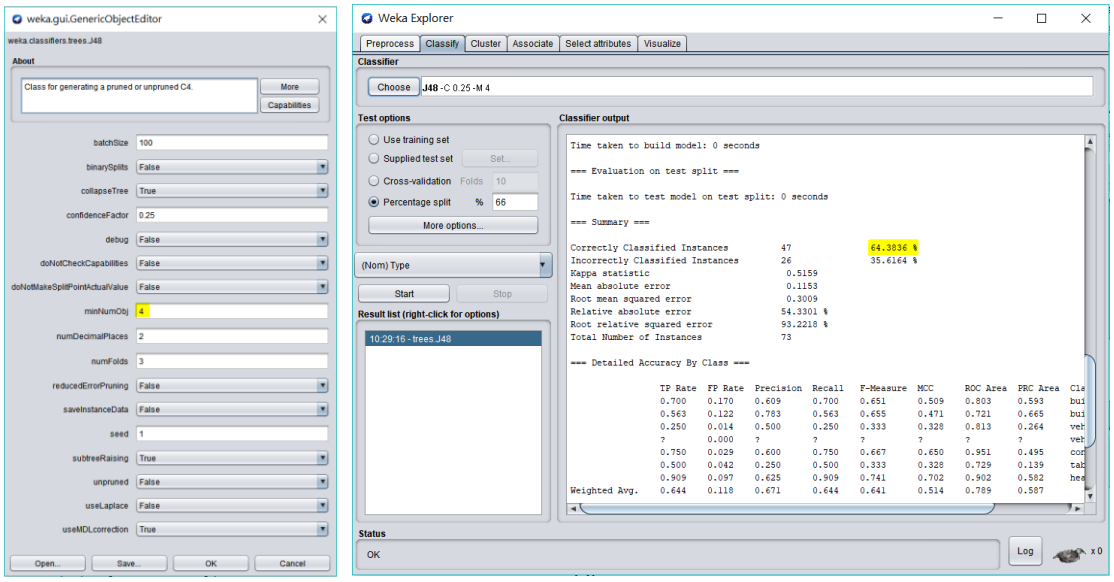

將 minNumObj 修改成 2，得精準度為 57.5342%。

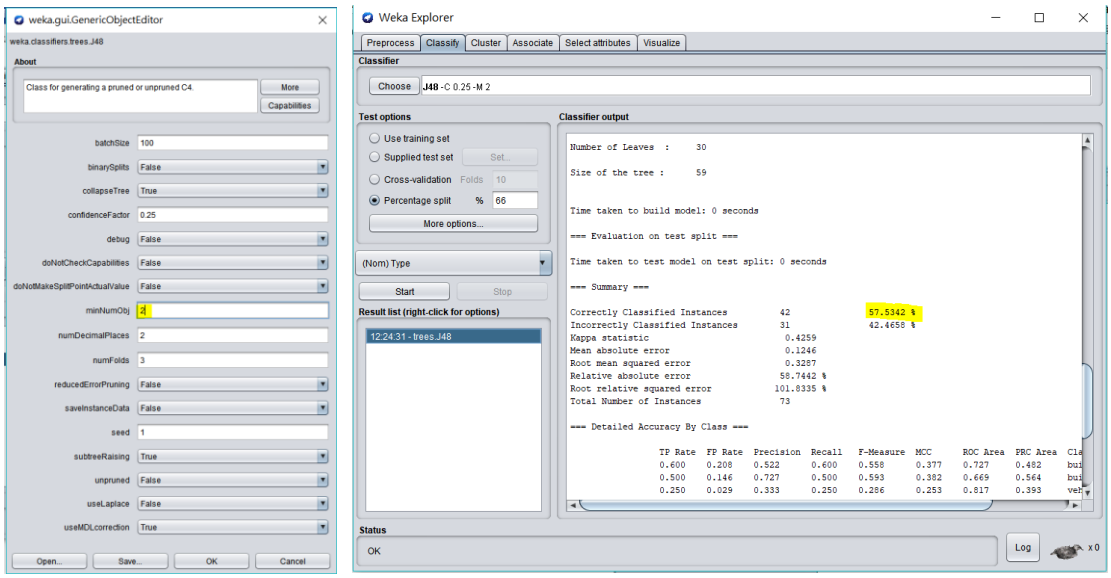

將 minNumObj 修改成 6，得精準度為 63.0137%。

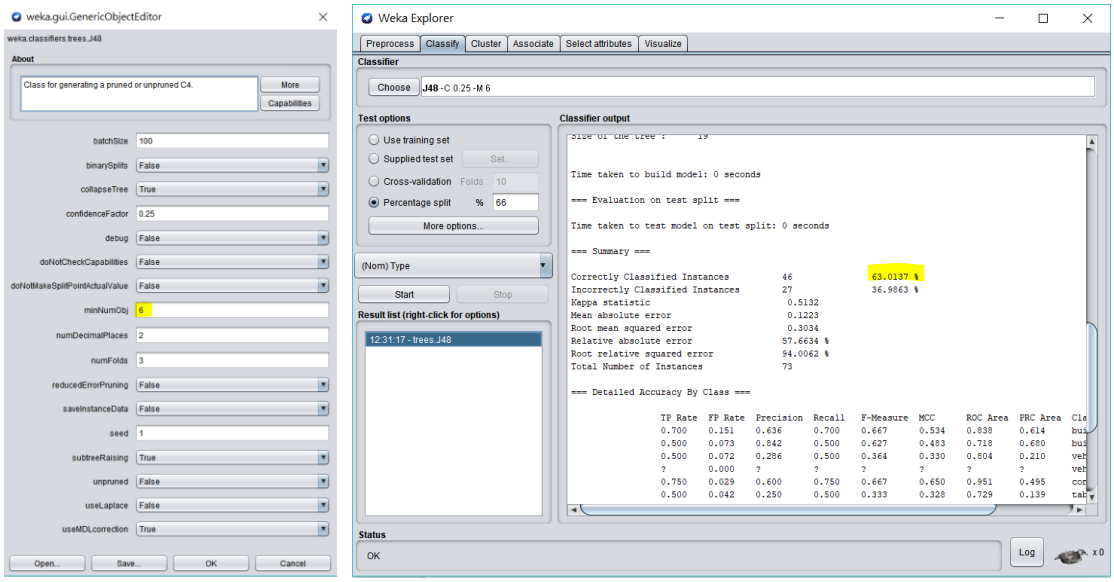

由上兩圖及多次測試後可得 minNumObj 在等於 4 時，會有最大精準值，原因在於若 minNumObj 太小，會使模型複雜度越高則容易 overfitting；但若 minNumObj 太大，因為資料數不足，反而會使精準度降低。

接著修改 Percentage split 參數，且固定 minNumObj = 4

當 Percentage split = 50%，準確度為 64.486%

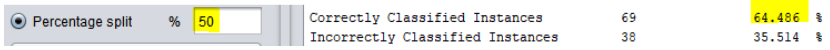

當 Percentage split = 55%，準確度為 55.2083%

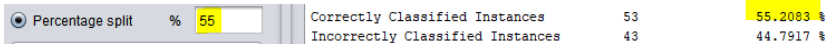

當 Percentage split = 60%，準確度為 65.1163%

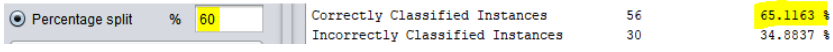

當 Percentage split = 65%，準確度為 61.3333%

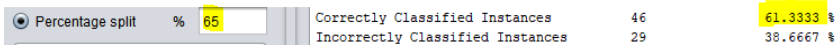

當 Percentage split = 70%，準確度為 60.9375%

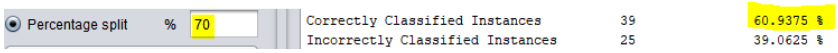

當 Percentage split = 75%，準確度為 62.2642%

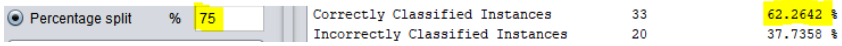

當 Percentage split = 80%，準確度為 62.7907%

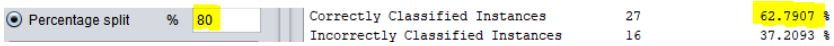

觀察趨勢後發現接近 Percentage split = 60% 與 Percentage split = 50% 時可能會有最大準確度。因此，代入 Percentage split = 58%, 59%, 61%, 62%, 48%, 49%,51%, 52% 進行測試。得當 Percentage split = 59% 時，會有最大準確度 65.9091%

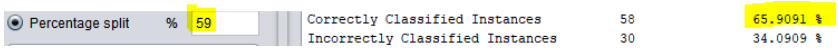

準確度會忽大忽小的原因在於，當 Percentage split 很大時，會有更大的可能挑到有差異的部分；當 Percentage split 很小時，則會有相對較小的可能挑到準確的部分。

訓練集的準確度通常是訓練數據上應用模型時獲得的準確度，而訓練集的準確度通常較測試集的準確度高是因為 overfitting，此時的分類模型是不可靠的。