ECT_HW9

利用 Keras 套件於 tensorflow 上，使用 CNN 深度學習演算法對 fashion_mnist 資料及進行分類，依序完成以下步驟及問題：

```
# 載入內建的MNIST dataset，並import matplotlib，以方便稍後顯示圖形及繪圖。
from keras.datasets import fashion_mnist
from keras.utils import np_utils
import numpy as np
import matplotlib.pyplot as plt

# 取得資料集
(X_train, y_train), (X_test, y_test) = fashion_mnist.load_data()
```

首先，載入所需套件並取得資料集。

```
# 將 X_train 及 X_test dataset 由原本三維轉為四維矩陣以符合CNN的需求
# 這是因為RGB圖片的格式為為width, height, channels，加上ID數維度為4。
# MNIST圖片為灰階因此其channel為1，轉換後的shape為(ID, width, height, channel)
X_train = X_train.reshape(X_train.shape[0], 28, 28, 1).astype('float32')
X_test = X_test.reshape(X_test.shape[0], 28, 28, 1).astype('float32')

# 將dataset的特徵值進行標準化，方法是除以255（因為圖像的像素點介於0~255之間）
# 可讓所有的特徵值介於 0 與 1 之間。除了可提昇模型預測的準確度，梯度運算時也能更快收斂。
X_train = X_train / 255
X_test = X_test / 255

# 進行 Onehot encoding，將彼此間不相關且非有序的categories轉換為連續性且是有序數值。
y_train = np_utils.to_categorical(y_train)
y_test_categories = y_test
y_test = np_utils.to_categorical(y_test)
```

並對資料進行前處理，將 X_train 及 X_test dataset 由原本三維轉為四維矩陣以符合CNN的需求，並將dataset的特徵值進行標準化，方法是除以255（因為圖像的像素點介於0~255之間），進行 Onehot encoding，將彼此間不相關且非有序的categories轉換為連續性且是有序數值。

1. 建立 CNN 模型

```
# 匯入建立模型所必要的模組
from keras.models import Sequential
from keras.layers import Dense, Dropout, Flatten, Conv2D, MaxPooling2D

# 建立一個線性堆疊模型，之後我們只要將建立的神經網路層依次加入即可。
model = Sequential()

# 建立第一個卷積層並加入model
# 該層有32個filters（即我們稱的filter或kernel）
# kernel大小為5x5，卷積後的圖形大小不變（即圖像周圍會補值）
# 輸入的圖形維度為28x28x1，並使用relu啟動函數。
# 由於定義了16個filters，因此本層會輸出16個28x28的影像。
model.add(Conv2D(filters=32, kernel_size=(5, 5), padding='same', input_shape=(28, 28, 1), activation='relu'))

# 建立池化層，定義pool size為(2,2)，即尺寸縮小為一半。
# 本層接收了上一層卷積層的16個28x28影像後，會輸出16個14x14的影像。
model.add(MaxPooling2D(pool_size=(2, 2)))

#建立第二個卷積層並加入model
# 這次定義該層有72個filters
# kernel大小為5x5，卷積後的圖形大小不變（即圖像周圍會補值）
# 輸入的圖形維度為(14,14,1)但可省略因為Keras,會自動判斷，使用relu啟動函數。
# 由於定義了36個filters，因此本層會輸出36個14x14的影像。
model.add(Conv2D(filters=72, kernel_size=(5, 5), padding='same', activation='relu'))

# 加入第二個池化層，參數與第一個池化層完全相同。本層會接收36個14x14影像後，輸出36個7x7的影像。
model.add(MaxPooling2D(pool_size=(2, 2)))

# 在各兩層的卷積與池化後，加入Dropout層，減少過度擬合
# Dropout會讓每次batch run都依據機率丟棄一定比例的神經元不予計算，使得每一次都好像在訓練不同的神經網路一樣。
# 下方的程式中，定義該Dropout層每次訓練時要丟棄25%的神經元。
 # 下方的程式中，定義該Dropout層每次訓練時要丟棄25%的神經元。
model.add(Dropout(0.25))

# 建立一個平坦層，將特徵值轉為一維資料以供後續的全連結層使用。
# 本層接收第二個池化層傳來的36x7x7（=1764）資料之後，轉為1維的1764。
model.add(Flatten())

# 建立全連結層中的隱藏層(即傳統神經網路中的全連結層)，指定其神經元數目為128個（此數目可調整），啟用函數使用Relu。
model.add(Dense(256, activation='relu'))

# 再加入一層Dropout來防止過度擬合。(此層亦可省略，可視執行結果來決定)
model.add(Dropout(0.5))

# 本模型的最後一層是輸出層，也就是要輸出十種0~9的分類值，一般我們都會使用softmax作為分類模型輸出層的啟動函數。
model.add(Dense(10, activation='softmax'))

# 使用summary指令review一下整個model。
model.summary()
```

2. 解釋設的參數（filter 數量、大小、 activation function 設置、 dropout)為何 ？

下方的程式中，建立第一個卷積層並加入model，該層有32個filters（即我們稱的filter或kernel），kernel大小為5×5，卷積後的圖形大小不變（即圖像周圍會補值），輸入的圖形維度為28x28x1，並使用relu啟動函數。由於定義了16個filters，因此本層會輸出16個28×28的影像。

```
model.add(Conv2D(filters=72, kernel_size=(5, 5), padding='same', activation='relu'))
```

Dropout會讓每次batch run都依據機率丟棄一定比例的神經元不予計算，使得每一次都好像在訓練不同的神經網路一樣。下方的程式中，定義該Dropout層每次訓練時要丟棄25%的神經元。

```
model.add(Dropout(0.25))
```

3. 評估訓練結果

訓練模型

```
# 使用compile來定義訓練的參數。
# 損失函數使用深度學習分類模型中最常用的交叉熵cross entropy
# 梯度下降法採取最常用的adam
# 模型的評估方式則是以accuracy為優先。
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

# 使用fit指令可開始訓練本CNN模型。x與y分別傳入特徵值及分類值。
# epochs=10 代表要執行10次訓練週期（即10次，每次的資料量為48000筆），每個訓練週期會將所有資料以每批次300筆來執行
# batch_size=300 每個訓練週期會將所有資料以每批次300筆來執行
# 即48000/300=160，每個訓練週期會執行160批次，每批次為300筆data
# 每訓練完一個週期，會計算此週期的accuracy與loss放到train_history變數中。
train_history=model.fit(x=X_train, y=y_train, validation_data=(X_test, y_test),
                        validation_split=0.2, epochs=35, batch_size=300, verbose=2)

#從下方的執行結果，可以看到loss愈來愈低，accuracy愈來愈高。
```

建立訓練模型，並設置validation_split=0.2(20%的資料當測試集)，epochs=35 (執行35次訓練週期)，batch_size=300 每個訓練週期會將所有資料以每批次300筆來執行。

```
Epoch 35/35
 - 7s - loss: 0.0320 - acc: 0.9881 - val_loss: 0.3292 - val_acc: 0.9269
```

第35次訓練所得之loss、acc、val_loss、val_acc。

4. 顯示 model.summary 結果

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d_3 (Conv2D)            (None, 28, 28, 32)        832
_________________________________________________________________
max_pooling2d_3 (MaxPooling2 (None, 14, 14, 32)        0
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 14, 14, 72)        57672
_________________________________________________________________
max_pooling2d_4 (MaxPooling2 (None, 7, 7, 72)          0
_________________________________________________________________
dropout_2 (Dropout)          (None, 7, 7, 72)          0
_________________________________________________________________
flatten_2 (Flatten)          (None, 3528)              0
_________________________________________________________________
dense_3 (Dense)              (None, 256)               903424
_________________________________________________________________
dense_4 (Dense)              (None, 10)                2570
=================================================================
Total params: 964,498
Trainable params: 964,498
Non-trainable params: 0
```

5. 準確率視覺化

定義一個show_train_history函式，我們只要將結果丟入，便可繪成圖表。
輸出結果如下：

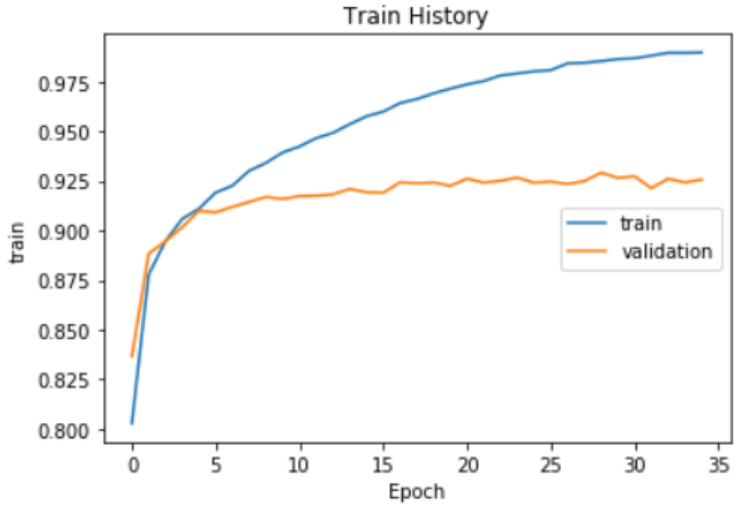

6. 誤差率視覺化

輸出結果如下：

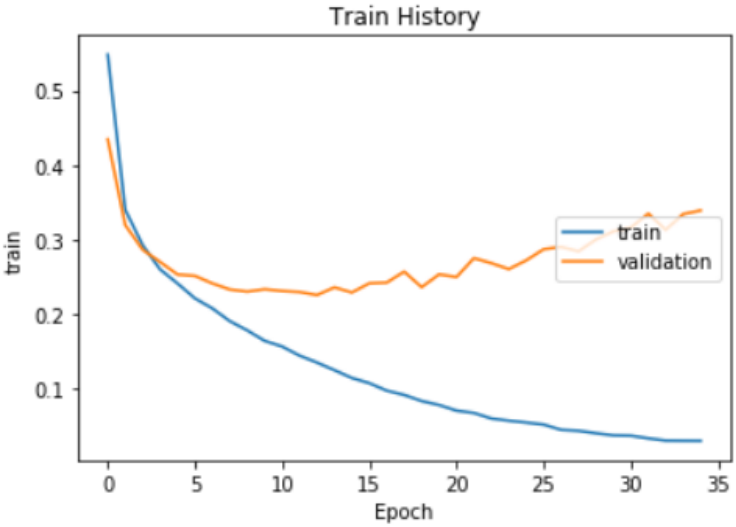

7. 整體模型準確率(於test set)

```
# 使用test dataset來評估模型的準確率。
scores = model.evaluate(X_test, y_test)
scores[1]
```

```
10000/10000 [==============================] - 1s 99us/step

0.9257
```

使用test dataset來評估模型的準確率可得0.9257

8. 混淆矩陣

```
# 判斷目前使用的模型是否混淆了某兩個類別，將某一label預測為另一個label。

import pandas as pd

prediction = model.predict_classes(X_test)

print(y_test.shape)

pd.crosstab(y_test_categories, prediction, rownames=['label'], colnames=['predict'])
```

predict label	0	1	2	3	4	5	6	7	8	9
0	902	1	9	12	3	1	66	0	6	0
1	1	988	0	6	3	0	1	0	1	0
2	21	0	865	6	62	0	45	0	1	0
3	14	2	9	923	32	0	18	0	2	0
4	0	1	29	13	913	0	41	0	3	0
5	0	0	0	0	0	994	0	5	0	1
6	112	1	46	20	64	0	750	0	7	0
7	0	0	0	0	0	11	0	973	0	16
8	3	0	0	1	0	4	3	1	988	0
9	0	0	0	0	0	5	0	21	1	973